




Modelli di database

*“Un buon database è come un archivio segreto:
rivelatore di verità celate nei bit.”*

- GPT-3.5-

Introduzione ai database



Dati e informazioni

Nella pratica quotidiana spesso si usano in modo intercambiabile i termini **dato** e **informazione**.

I dati dell'insieme della figura seguente non forniscono alcuna informazione utile finchè non si definisce cosa ciascun dato rappresenta e le eventuali relazioni esistenti tra i dati stessi.



Il dato *Warren*, come il dato *105* e tutti gli altri, senza chiave di interpretazione gli dia un significato, non costituisce informazione per nessuno.



Cosa è un dato?

*“Ciò che è immediatamente presente alla conoscenza, prima di ogni forma di elaborazione.
Con uso più specifico, in informatica, dati, elementi di un'informazione costituiti da simboli (numeri,
lettere: d. numerici, alfabetici, alfanumerici) che devono essere elaborati, per lo più elettronicamente,
secondo un determinato programma”*
Definizione di **dato** - treccani.it

Fatti raccolti insieme per poi essere interpretati.



Cosa è un'informazione?

“Azione di dare forma a qualcosa”

Definizione di **informazione** - [treccani.it](https://www.treccani.it)

L'informazione è il processo utilizzato per dare un senso ad un dato.



Dati e informazioni

I dati sono utilizzabili (danno informazione) se si attribuisce loro una chiave di interpretazione che consente di comprendere il loro significato, cioè i fatti che essi codificano.



Warren	150	Larry	
Bernard	105	95	Bill
	123		

Se ai dati *Warren*, *Bernard*, *Larry* e *Bill*, associamo la chiave di interpretazione “Nome degli uomini tra i più ricchi al mondo” e ai dati “150, 123, 105 e 95” associamo la chiave di interpretazione “Milioni di dollari” otteniamo l’informazione completa.



Le tabelle

I dati precedenti risultano facilmente interpretabili se rappresentati in forma tabellare

Uomini più ricchi al mondo	
Nome	Patrimonio (milioni di dollari)
Warren	105
Bernard	150
Larry	95
Bill	123



Dati = Business

I dati, e di conseguenza le informazioni, sono il patrimonio più grande che un'organizzazione possiede.

Una volta che i dati vengono raccolti devono essere necessariamente memorizzati in modo che si possa facilmente:

- recuperarli in base a determinati criteri di ricerca;
- aggiungerne di nuovi;
- modificarli;
- cancellarli.



Teoria delle basi di dati

In campo informatico, la **teoria delle basi di dati** studia come organizzare al meglio grandi quantità di informazioni, per poterle gestire in modo:

- **semplice**: in quanto devono essere facilmente fruibili in applicazioni differenti e da parte di utenti differenti;
- **efficiente**: l'utilizzo delle risorse deve essere ottimizzato in termini di tempo e spazio;
- **efficace**: le informazioni devono rappresentare la realtà che si vuole analizzare (ad esempio, un'età non può essere negativa);
- **sicuro**: le operazioni sui dati sono permesse solo a soggetti identificabili e autorizzati.



Database e DBMS

Un **database** (in italiano **base di dati**) può essere considerato come una raccolta di dati logicamente correlati, utilizzata per modellare una realtà.

Un **DBMS** (*Data Base Management System*) è un insieme di strumenti software che è in grado di gestire grandi collezioni di dati, compresa la loro definizione e il modo con cui vengono fisicamente archiviati.

Un DBMS deve garantire le seguenti proprietà:

- gestione efficiente;
- condivisione e concorrenza;
- persistenza e affidabilità;
- sicurezza.



Gestione efficiente

Quando in un insieme di database sono disponibili milioni di dati, la loro utilità viene meno se, ogni volta che bisogna accedere ad un determinato dato, si deve attendere un tempo indefinito.

Il DBMS, pertanto, non deve essere un collo di bottiglia nei tempi di elaborazione ed inoltre deve permettere a più utenti di consultare i dati.

I DBMS offrono una serie di strutture (indici) utilizzate per effettuare ricerche in modo efficiente.



Condivisione e concorrenza

Il DBMS deve garantire la sincronizzazione per l'accesso condiviso alla risorsa dato.

Se la sincronizzazione non venisse gestita si potrebbero creare, ad esempio, dei casi in cui due utenti prelevano contemporaneamente 100€ da un conto corrente la cui disponibilità è pari a 150€.



Persistenza e affidabilità

Le tipologie di operazioni (chiamate transazioni) che si possono effettuare su un database sono molteplici e tutte devono essere svolte rispettando alcune proprietà, note con la sigla **ACID**, acronimo di:

- **Atomicity:** l'operazione è eseguita nella sua interezza o non è eseguita affatto, deve essere un'operazione atomica;
- **Consistency:** un'esecuzione corretta della transazione deve portare il DB in un nuovo stato consistente;
- **Isolation:** non si deve permettere di “visionare” i risultati di operazioni intermedie ad altre transazioni, ma solo alla sua normale e corretta terminazione si possono vedere i risultati;
- **Durability:** al termine di una transazione i risultati devono essere permanenti.



Sicurezza

Il DBMS deve gestire il controllo degli accessi per assicurare che i dati siano visibili solo da particolari utenti o gruppi di utenti che siano in possesso dei diritti necessari. Si possono definire meccanismi di autorizzazione in modo che un utente sia autorizzato a leggere solo una parte dei dati, quelli di sua competenza.




Architettura dei DBMS

L'architettura standard del DBMS (**ANSI/SPARC**) si articola su tre livelli:

- **schema esterno:** ogni utente ha un proprio spazio di lavoro che si interfaccia con la base di dati mediante un'applicazione, o direttamente tramite un linguaggio apposito.
- **schema logico:** descrizione dell'intera base di dati nel modello logico; è la cerniera tra ciò che vedono gli utenti e quello che viene effettivamente salvato.
- **schema interno (o fisico):** rappresentazione dello schema logico per mezzo delle strutture fisiche di memorizzazione (file, record e strutture di accesso).

Architettura dei DBMS





Indipendenza logica e fisica

Con l'organizzazione a tre livelli, un DBMS permette di ottenere indipendenza fisica e logica dei dati.

Con **indipendenza fisica** si intende la possibilità di modificare l'organizzazione fisica dei dati senza dover conseguentemente modificare l'organizzazione logica e i programmi applicativi che agiscono sul database.

Per **indipendenza logica**, invece, si intende la possibilità di modificare lo schema logico del database senza dover modificare i programmi applicativi non interessati alla modifica.

Modello logico

Ogni DBMS è caratterizzato dall'organizzare i dati secondo uno specifico modello logico.


Il **modello logico** è uno strumento che permette di strutturare/organizzare i dati in modo che gli vengano assegnati dei significati (informazioni) che altrimenti non avrebbero.

Ad esempio si può pensare a modelli che memorizzano i dati utilizzando dei record a lunghezza fissa oppure sotto forma di grafo, etc.

record a lunghezza fissa

<A,B,C,D,E>

grafo





Modello logico

Negli anni sono stati proposti molti modelli logici:

- gerarchico (anni '60)
- reticolare (anni '60)
- relazionale (anni '70)
- a oggetti (anni '80)
- XML (anni '90)
- schema-less (anni '60), detti anche modelli NoSQL.




Modello concettuale

Nella progettazione di un database si utilizza anche il **modello concettuale**.

Lo scopo di tale modello è quello di costruire e definire una rappresentazione corretta e completa della realtà di interessi utilizzando formalismi che non dipendono dal modello logico e quindi di conseguenza dal DBMS che si adotterà.


Il modello relazionale: definizioni e strutture



Modello relazionale

Il **modello relazionale** è stato definito da [Edgar F. Codd](#) all'inizio degli anni '70 e rappresenta il database come un insieme di tabelle che possono essere connesse tra loro mediante, appunto, relazioni.

Il modello relazionale viene considerato attualmente il modello più semplice ed efficace, perché è vicino al modo naturale della strutturazione dei dati stessi.





Relazione

Utilizzeremo il termine *relazione* in tre accezioni che differiscono in modo importante:

- *relazione matematica*, secondo la definizione normalmente data nella teoria degli insiemi. Da questa nozione derivano le altre due;
- *relazione* secondo la definizione del modello relazionale che presenta alcune differenze rispetto a quella della teoria degli insiemi;
- *relazione*, come traduzione di *relationship*, utilizzato, come vedremo nella discussione della progettazione concettuale, per descrivere legami tra entità del mondo reale.

Nei primi due casi si usa in inglese il termine *relation*, che quindi non è ambiguo rispetto a *relationship*. Talvolta sono usate altre traduzioni per *relationship*, come *associazione* o *correlazione*.



Relazione matematica

Dati due insiemi D_1 e D_2 , si chiama **prodotto cartesiano** di D_1 e D_2 e si indica con $D_1 \times D_2$ l'insieme delle coppie ordinate (v_1, v_2) , tali che v_1 è un elemento di D_1 e v_2 è un elemento di D_2 .

Per esempio, dati gli insiemi $A = \{1, 2, 4\}$ e $B = \{a, b\}$, il prodotto cartesiano $A \times B$ sarà un insieme formato da sei coppie: $\{(1,a), (1,b), (2,a), (2,b), (4,a), (4,b)\}$.

Una **relazione matematica** sugli insiemi D_1 e D_2 (chiamati **domini** della relazione) è un sottoinsieme di $D_1 \times D_2$.

Dati gli insiemi A e B dell'esempio precedente una possibile relazione matematica su A e B è costituita dall'insieme di coppie $\{(1,a), (2,b), (4,a)\}$.



Relazione matematica

Le definizioni precedenti di prodotto cartesiano e relazione matematica fanno riferimento a due insiemi, ma possono essere generalizzati rispetto al numero di insiemi.

Le relazioni possono essere rappresentate graficamente sotto forma tabellare. Le due tabelle riportate di seguito descrivono il prodotto $A \times B$ e la relazione matematica su A e B prima descritta.

1	a
1	b
2	a
2	b
4	a
4	b

1	a
2	b
4	a



Relazioni e tabelle

Le relazioni (e le corrispondenti tabelle) possono essere utilizzate per rappresentare i dati di interesse per qualche applicazione. Per esempio, la relazione di seguito contiene i dati relativi ai risultati di un insieme di partite di calcio.

Juventus	Lazio	3	1
Lazio	Milan	2	0
Juventus	Roma	1	2
Roma	Milan	0	1

La relazione è un sottoinsieme del prodotto cartesiano: Stringa x Stringa x Intero x Intero



Relazioni con attributi

Con riferimento all'uso che facciamo delle relazioni per organizzare i dati nelle nostre basi di dati, possiamo dire che ciascuna **tupla** (o **n-upla**) (riga della tabella) contiene dati tra loro collegati, anzi stabilisce un legame tra loro: per esempio la prima tupla della relazione precedente stabilisce un legame tra i valori *Juventus*, *Lazio*, 3 e 1 ad indicare che il risultato della partita fra Juventus e Lazio è 3 a 1.

Possiamo associare a ciascuna occorrenza di dominio nella relazione un nome, detto **attributo**, che descrive il ruolo giocato dal dominio stesso.

Dovendo identificare univocamente le componenti, gli attributi di una relazione devono essere diversi l'uno dall'altro.



Relazioni con attributi

Per esempio, per la relazione relativa alle partite, possiamo usare nomi come SquadraDiCasa, SquadraOspitata, RetiCasa, RetiOspitata; nella rappresentazione tabellare, utilizziamo gli attributi come intestazione delle colonne.

SquadraDiCasa	SquadraOspitata	RetiCasa	RetiOspitata
Juventus	Lazio	3	1
Lazio	Milan	2	0
Juventus	Roma	1	2
Roma	Milan	0	1



Relazioni e basi di dati

Una base di dati è in generale costituita da più relazioni, le cui tuple contengono valori comuni, ove necessario per stabilire corrispondenze.

STUDENTI

Matricola	Cognome	Nome	Data di nascita
276545	Rossi	Maria	25/11/1995
455745	Neri	Anna	23/04/1999
200768	Verdi	Fabio	12/02/1997

ESAMI

Studente	Voto	Corso
276545	28	01
455745	24	04

CORSI

Codice	Titolo	Docente
01	Analisi I	Melli
03	Chimica	Belli
04	Fisca	Giani



Relazioni e basi di dati

Analizzando la base di dati rappresentata nella slide precedente si può notare che:

- la prima relazione contiene informazioni relative a un insieme di studenti;
- la terza relazione contiene informazioni su alcuni corsi;
- la seconda relazione informazioni relative a esami: questa relazione fa riferimento ai dati contenuti nelle altre due: agli studenti, attraverso i numeri di matricola, e ai corsi, attraverso i relativi codici.

Il modello relazionale è **basato su valori**: i riferimenti tra dati in relazioni diverse sono rappresentati per mezzo di valori dei domini che compaiono nelle tuple.



Informazioni incomplete e valori nulli

Il modello relazionale impone un certo grado di rigidità: le informazioni devono essere rappresentate per mezzo di tuple di dati omogenee.

In molti casi i dati disponibili possono non corrispondere esattamente al formato previsto. Per esempio, in una relazione sulla schema:

PERSONE(Cognome, Nome, Indirizzo, Telefono)

il valore dell'attributo *Telefono* potrebbe non essere disponibile per tutte le tuple. In questo caso, se i numeri di telefono fossero rappresentati per mezzo di interi, potremmo per esempio utilizzare lo zero per indicare l'assenza di un valore significativo.



Informazioni incomplete e valori nulli

La scelta appena descritta comporta due problemi:

- non sempre è disponibile un valore di dominio disponibile per rappresentare un'assenza di informazione;
- la distinzione tra valori “veri” e valori “fittizi” è nascosta e quindi i programmi che utilizzano il database devono essere a conoscenza di questa distinzione.

Quindi per rappresentare la non disponibilità di valori viene utilizzato il **valore nullo**. Nelle rappresentazioni tabellari utilizzeremo per il valore nullo il simbolo NULL.



Informazioni incomplete e valori nulli

STUDENTI

Matricola	Cognome	Nome	Data di nascita	Data di laurea
276545	Rossi	Maria	25/11/1995	12/12/2015
455745	Neri	Anna	23/04/1999	NULL
200768	Verdi	Fabio	12/02/2000	NULL

E' possibile osservare che in questo caso il valore NULL denota che gli studenti Neri e Verdi non si sono ancora laureati.




Informazioni incomplete e valori nulli

E' necessario controllare opportunamente la presenza dei valori nulli nelle relazioni: solo alcune configurazioni devono essere ammesse.

Esempio: nella relazione precedente ha senso avere la data di nascita NULL, e il nome?

Utilizzando il DDL è possibile specificare che i nulli sono ammessi solo su alcuni attributi e non su altri.

Il modello relazionale: vincoli di integrità





Vincoli di integrità

In molti casi non è vero che qualsiasi insieme di tuple sullo schema rappresenti informazioni corrette per l'applicazione.

STUDENTI

Matricola	Cognome	Nome	Data di nascita
200768	Verdi	Fabio	12/02/1997
937653	Rossi	Luca	10/10/1998
937653	Bruni	Mario	01/12/1999

ESAMI

Studente	Voto	Lode	Corso
200768	36	no	05
937653	28	si	01
937653	30	si	01
276545	25	no	01

CORSI

Codice	Titolo	Docente
01	Analisi I	Giani
03	Chimica	Melli
04	Chimica	Belli



Vincoli di integrità

- Nella prima tupla della relazione ESAMI abbiamo un voto pari a 36 che, nel sistema italiano, non è ammissibile.
- Nella seconda tupla della relazione ESAMI viene indicato che è stata attribuita la lode in un esame in cui il voto è 28, il che è impossibile.
- Le ultime due tuple della relazione STUDENTI contengono informazioni su due studenti diversi con lo stesso numero di matricola.
- La quarta tupla della relazione ESAMI presenta, per l'attributo Studente, un valore che non compare fra i numeri di matricola nella relazione STUDENTI.
- La prima tupla della relazione ESAMI presenta, per l'attributo Corso, un valore che non compare fra i codici nella relazione CORSI.

Vincoli di integrità

STUDENTI

Matricola	Cognome	Nome	Data di nascita
200768	Verdi	Fabio	12/02/1997
937653	Rossi	Luca	10/10/1999
937653	Bruni	Mario	01/12/1995

ESAMI

Studente	Voto	Lode	Corso
200768	36	no	05
937653	28	si	01
937653	30	si	03
276545	25	no	01

CORSI

Codice	Titolo	Docente
01	Analisi I	Giani
03	Chimica	Melli
04	Chimica	Belli



Vincoli di integrità

Per evitare le situazioni appena descritte è stato introdotto il concetto di **vincolo di integrità**, come proprietà che deve essere soddisfatta dalle istanze che rappresentano informazioni corrette per l'applicazione.

E' possibile classificare i vincoli in due categorie:

- **vincolo intrarelazionale** se il suo soddisfacimento è definito rispetto a singole relazioni. A sua volta si suddivide in:
 - **vincolo di tupla**: è un vincolo che può essere valutato su ciascuna tupla indipendentemente dalle altre;
 - **vincoli su valori** o **vincolo di dominio**: è un vincolo definito con riferimento a singoli valori in quanto impone una restrizione sul dominio dell'attributo.
- **vincolo interrelazionale** se coinvolge più relazioni.



Vincoli di tupla

I vincoli di tupla esprimono condizioni sui valori di ciascuna tupla, indipendentemente dalle altre tuple.

Una possibile sintassi per esprimere vincoli di questo tipo è quella che permette di definire espressioni booleane con operazioni di confronto tra i valori di attributo o espressioni aritmetiche su valori di attributo.

$\text{Voto} \geq 18 \text{ AND } \text{Voto} \leq 30$

$(\text{NOT}(\text{Lode} = \text{'si'})) \text{ OR } \text{Voto} = 30$

Il primo vincolo è un **vincolo di dominio** in quanto coinvolge un solo attributo.



Chiavi

Una **chiave** è un insieme di attributi utilizzato per identificare univocamente le tuple di una relazione.

Un insieme K di attributi è chiave di una relazione r se:

- la relazione r non contiene due tuple distinte con gli stessi valori per K (**univocità**);
- K è **minimale** (cioè non esistono sottoinsiemi propri di K ancora univoci).

Se è definita solo la prima proprietà, K è una **superchiave** di r .

L'insieme degli attributi {Matricola, Nome} è univoco, ma non minimale, quindi è una superchiave, ma non è una chiave.



Chiavi

Ogni relazione deve avere necessariamente una chiave.

La chiave permette di stabilire efficientemente quelle corrispondenze fra dati contenuti in relazioni diverse che caratterizzano il modello relazionale come “modello basato su valori”.



Chiavi e valori nulli

Su una delle chiavi (ATTENZIONE: una relazione può avere più chiavi), detta **chiave primaria** si vieta la presenza di valori nulli; sulle altre, i valori nulli sono in genere ammessi.

Gli attributi che costituiscono la chiave primaria vengono spesso evidenziati attraverso la sottolineatura.

STUDENTI(Matricola, Cognome, Nome, Data di nascita)

ESAMI(Studente, Voto, Lode, Corso)

CORSI(Codice, Titolo, Docente)



Chiavi e valori nulli

La maggior parte dei riferimenti tra relazioni vengono realizzati attraverso i valori della chiave primaria.

In quasi tutti i casi reali è possibile trovare attributi i cui valori sono identificanti e sempre disponibili. Quando ciò non accade, è necessario introdurre un attributo aggiuntivo, un codice, probabilmente non significativo dal punto di vista dell'applicazione, che viene in qualche modo generato e attribuito a ciascuna tupla all'atto dell'inserimento. In questo caso la chiave prende in nome di **chiave artificiale**.



Vincoli di integrità referenziale

Un **vincolo di integrità referenziale** fra un insieme di attributi X di una relazione R_1 e un'altra relazione R_2 è soddisfatto se i valori su X di ciascuna tupla dell'istanza di R_1 compaiono come valori della chiave (primaria) dell'istanza di R_2 .

I valori assunti dall'insieme X di R_1 possono essere esclusivamente valori assunti effettivamente dalla chiave primaria di R_2 .

I valori assunti da un attributo nella relazione referenziante devono esistere effettivamente come valori di un attributo nell'istanza della relazione referenziata.

L'insieme di attributi X di R_1 costituisce una **chiave esterna (foreign key)** di R_1 .

Vincoli di integrità referenziale

STUDENTI

<u>Matricola</u>	Cognome	Nome	Data di nascita
200768	Verdi	Fabio	12/02/1997
937653	Rossi	Luca	10/10/1999
163733	Bruni	Mario	01/12/1995

ESAMI

<u>Studente</u>	Voto	Lode	<u>Corso</u>
200768	30	no	04
937653	28	no	01
937653	30	si	03
163733	25	no	01

CORSI

<u>Codice</u>	Titolo	Docente
01	Analisi I	Giani
03	Chimica	Melli
04	Chimica	Belli



Vincoli di integrità referenziale

Nell'esempio precedente è possibile notare come gli attributi che formano la chiave primaria di ESAMI rappresentano chiavi esterne verso le relazioni STUDENTI e CORSI.



ESERCIZI

1. Considerare le informazioni per la gestione dei prestiti di una biblioteca personale. Il proprietario presta libri ai suoi amici, che indica attraverso un nome, un cognome e un codice fiscale e fa riferimento ai libri attraverso i titoli (non possiede due titoli con lo stesso titolo). Quando presta un libro prende nota della data prevista di restituzione. Definire uno schema di relazione per rappresentare questa informazioni e mostrare un'istanza in forma tabellare. Per ogni relazione indicare la chiave.
2. Definire uno schema di base di dati per organizzare le informazioni di un'azienda che ha impiegati (ognuno con codice fiscale, cognome, nome e data di nascita), filiali (con codice, sede e direttore, che è un impiegato). Ogni impiegato lavora presso una filiale. Indicare le chiavi e i vincoli di integrità referenziale dello schema. Mostrare un'istanza della base di dati e verificare che soddisfa i vincoli.

Valutare per ogni esercizio le eventuali esigenze di rappresentazione di valori nulli.